Clasificación de coberturas territoriales con CNN

Trabajo Practico Integrador

GASPAR IGNACIO QUINTANA CONFORTI
17/06/2026

Introducción y Objetivos

Las imágenes satelitales son una fuente clave de información territorial, pero clasificarlas manualmente es inviable a escala. Este trabajo entrena una red neuronal convolucional desde cero para clasificar automáticamente imágenes del satélite Sentinel-2 en 10 tipos de cobertura del suelo.



Objetivo General

Desarrollar, entrenar y evaluar una CNN propia sobre el dataset EuroSAT RGB.

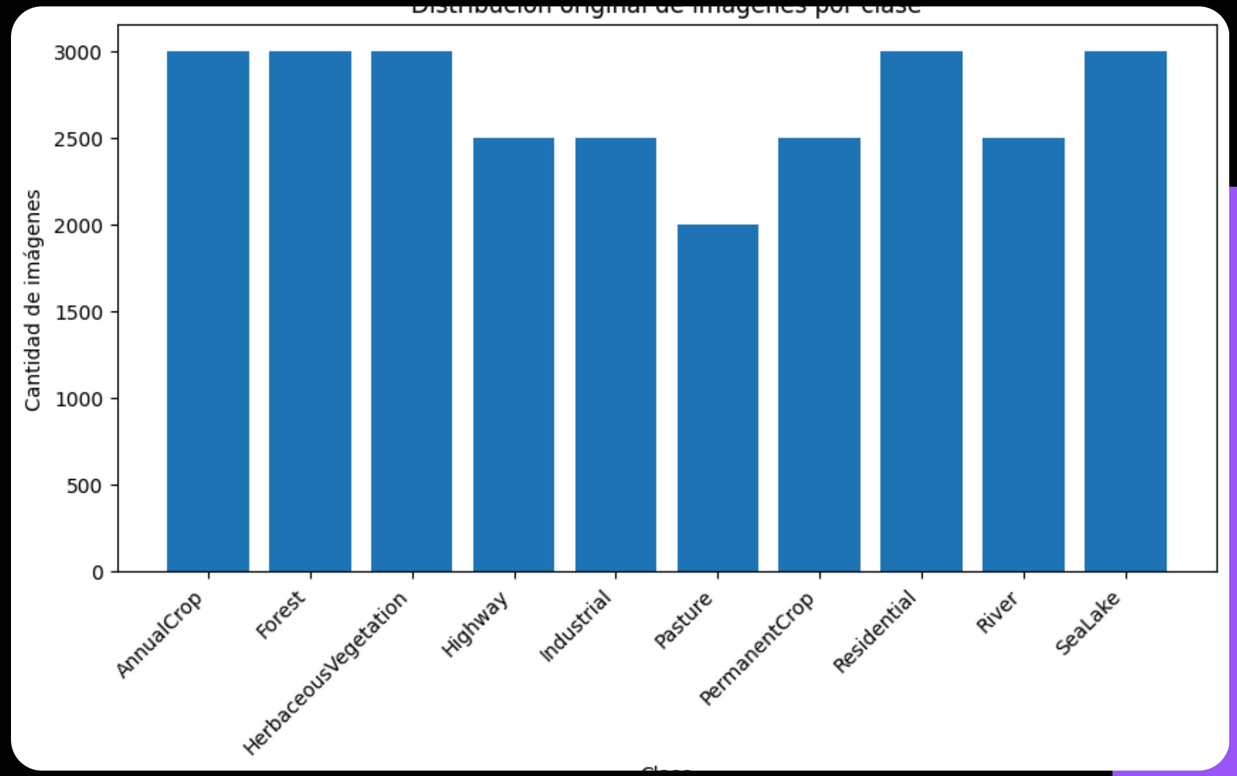
Objetivos Específicos

- Analizar el dataset EuroSAT RGB
- Diseñar el preprocesamiento adecuado al problema
- Implementar una arquitectura CNN propia desde cero
- Ejecutar un proceso experimental progresivo
- Comparar el modelo propio con un modelo preentrenado
- Evaluar y comparar los modelos entrenados
- Diagnosticar el comportamiento del modelo durante el entrenamiento .
- Interpretar los errores del modelo final
- Documentar las limitaciones identificadas
- Sintetizar las conclusiones del proceso experimental

Descripción del DataSet

Dataset	EuroSatRGB
Fuente	Sentinel-2
Total imágenes	27.000
Tamaño	64×64 px, RGB
Link	EuroSat Github

Dataset público de imágenes satelitales del programa Copernicus (ESA), con 27.000 imágenes de 64×64 píxeles distribuidas en 10 clases de uso del suelo. La distribución entre clases es aproximadamente balanceada, lo que lo hace ideal para entrenar una CNN sin necesidad de técnicas de balanceo.



Análisis Exploratorio

Las 10 clases representan tipos de uso y cobertura del suelo desde una perspectiva cenital (vista desde arriba). El modelo no debe reconocer objetos aislados, sino configuraciones espaciales: texturas, formas geométricas y trazados característicos de cada categoría.

La principal dificultad detectada durante el análisis es la similitud visual entre clases: los distintos tipos de vegetación y cultivo (AnnualCrop, PermanentCrop, HerbaceousVegetation, Pasture) comparten tonos verdes muy parecidos, y las clases con patrones lineales (Highway, River) son difíciles de distinguir a 64×64 píxeles.



Preprocesamiento Aplicado

Transformaciones y justificaciones

Las imágenes se prepararon para entrar a la red mediante normalización y división estratificada. No se aplicó redimensionamiento ni conversión de color porque el dataset ya provee imágenes en 64×64 píxeles RGB. Cada transformación se justificó técnicamente en función del problema y los datos disponibles.

Muestra de trabajo: 500 imágenes por clase División:

- **70% entrenamiento**
- **15% validación**
- **15% prueba, estratificada**

Preprocesamiento aplicado

Transformación	Configuración	Justificación
Redimensionamiento	No aplicado	Imágenes ya en 64×64 píxeles
Conversión de color	No aplicada	Imágenes ya en RGB
Normalización	rescale = 1/255	Píxeles al rango [0,1] para gradientes es
División de datos	70% / 15% / 15%	Train / Val / Test estratificada por clase
Codificación etiquetas	One-hot (categorical)	Requerido por categorical_crossentropy
Augmentation (final)	Flips H/V + rot 90° + zoom 10%	Refuerza variedad sin bordes artificiales
Batch size	32	Equilibrio entre gradiente estable y men

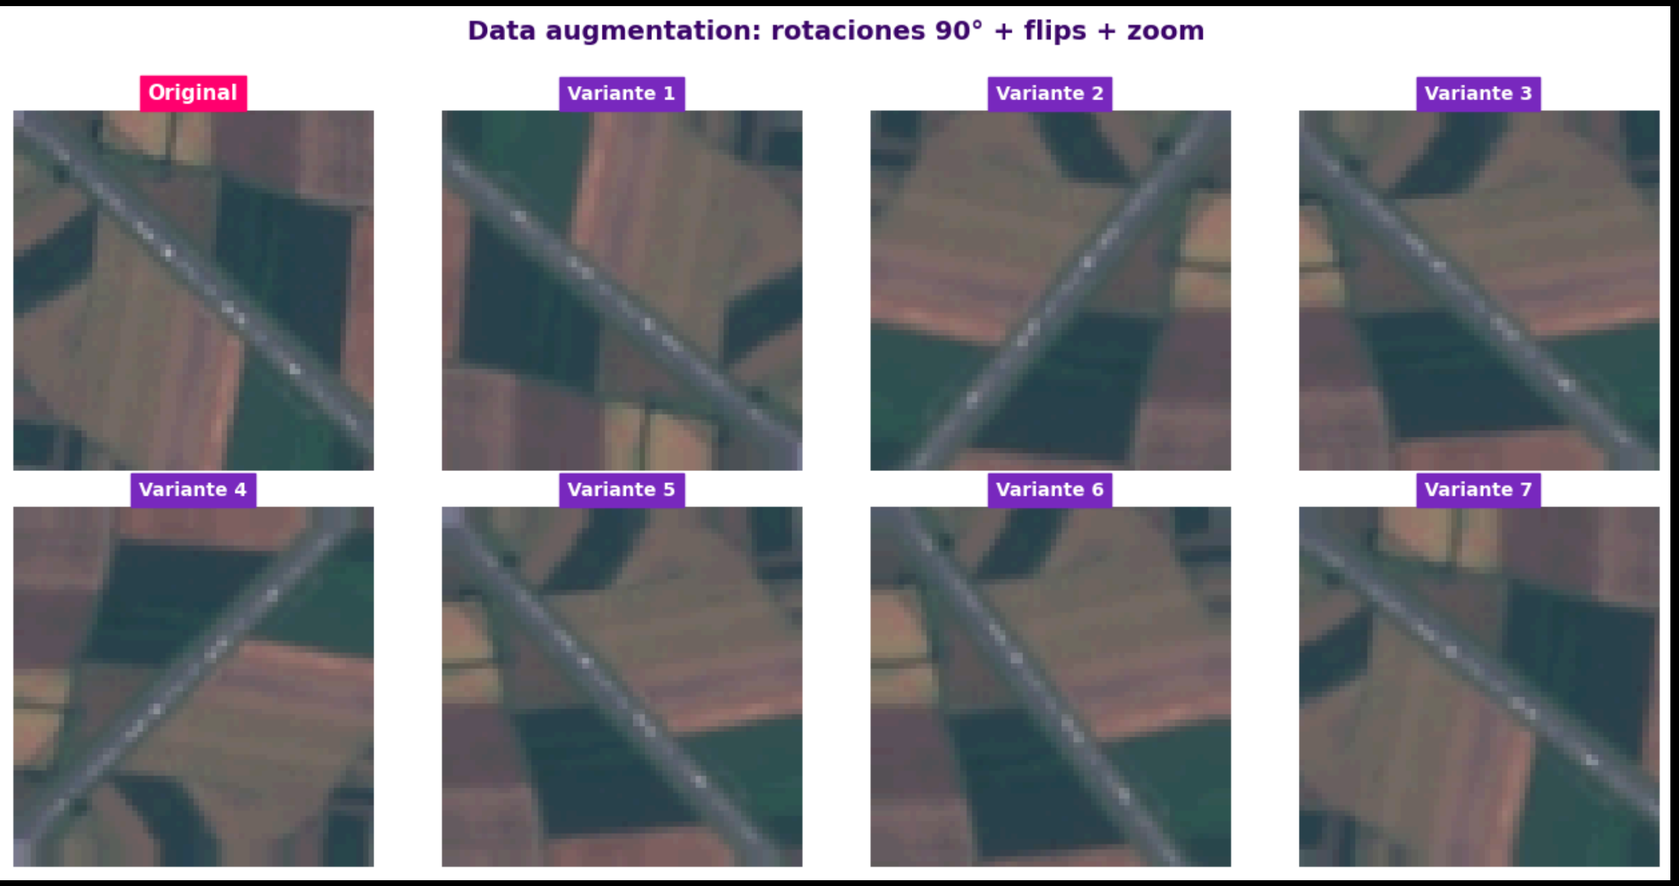
Pipeline de Transformaciones

Cada imagen del dataset atraviesa tres etapas antes de entrar a la red: se conserva la imagen original (64×64 RGB), se normaliza dividiéndola por 255 para llevar los píxeles al rango [0,1], y durante el entrenamiento se aplica data augmentation para aumentar la variedad de los datos.



La normalización estabiliza los gradientes durante el entrenamiento. El augmentation solo se aplica al conjunto de entrenamiento, no a validación ni prueba.

Data Augmentation



El data augmentation aplica transformaciones aleatorias a las imágenes de entrenamiento en cada época, generando variantes que el modelo nunca ve dos veces iguales. Esto reduce el sobreajuste y aumenta la variedad de los datos sin necesidad de cargar más imágenes.

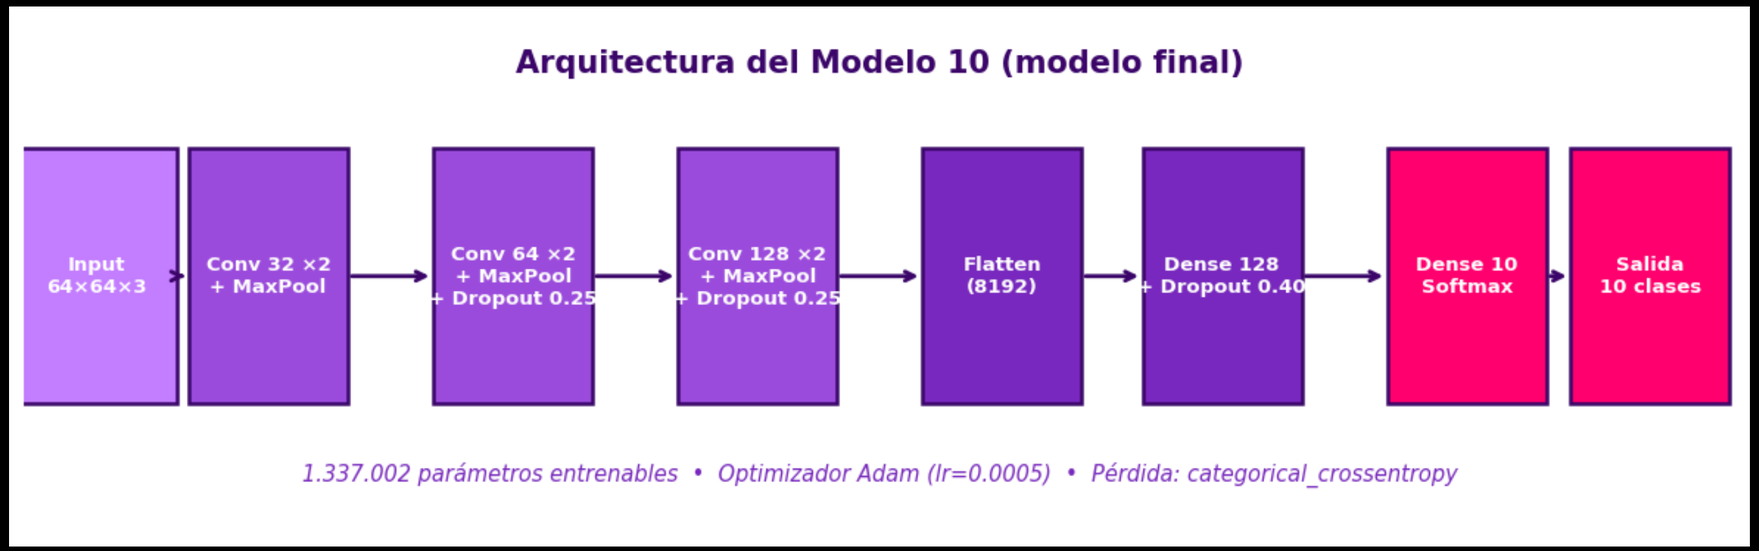
¿Por qué funciona especialmente bien en imágenes satelitales?
Al estar tomadas desde una perspectiva cenital, no tienen una orientación "correcta": un bosque sigue siendo un bosque rotado o espejado. Esto valida transformaciones que en otros datasets serían riesgosas, como el flip vertical o las rotaciones completas.

Flips horizontal y vertical · Rotaciones de 90° exactos · Zoom suave (10%)

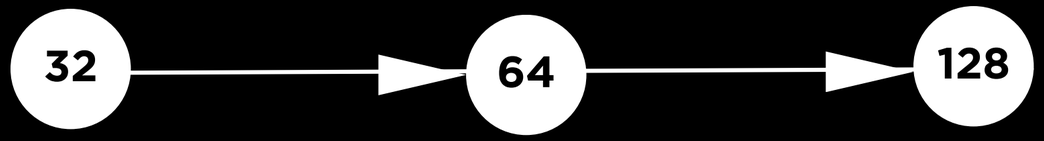
No se modifica el color: es una característica discriminativa clave (verde = vegetación, azul = agua, gris = urbano).

Arquitectura del modelo CNN

El modelo final está compuesto por tres bloques convolucionales dobles inspirados en la familia VGG, seguidos de una cabeza densa para la clasificación. Cada bloque tiene dos convoluciones consecutivas antes del pooling, lo que permite aprender patrones más ricos con menos parámetros que usando un solo kernel grande.



- 1.337.002 parámetros entrenables
- Activaciones ReLU en capas ocultas, Softmax en la salida
- Optimizador Adam (learning rate = 0.0005)
- Función de pérdida: categorical_crossentropy
- Regularización: Dropout en bloques convolucionales (0.25) y capa densa (0.40)



Diseño Experimental

Se entrenaron 11 modelos en 4 bloques experimentales, modificando una sola variable por experimento. Esta metodología permite atribuir cada mejora (o empeoramiento) a un cambio específico, en lugar de tener que adivinar a cuál de varios cambios simultáneos se debe la diferencia.

CADA BLOQUE ATACA UN PROBLEMA OBSERVADO EN EL ANTERIOR:

- El Bloque 1 estableció una línea base con pocos datos.
- El Bloque 2 aumentó la muestra y exploró regularización.
- El Bloque 3 introdujo data augmentation.
- El Bloque 4 refinó el augmentation con rotaciones específicas para imágenes satelitales.

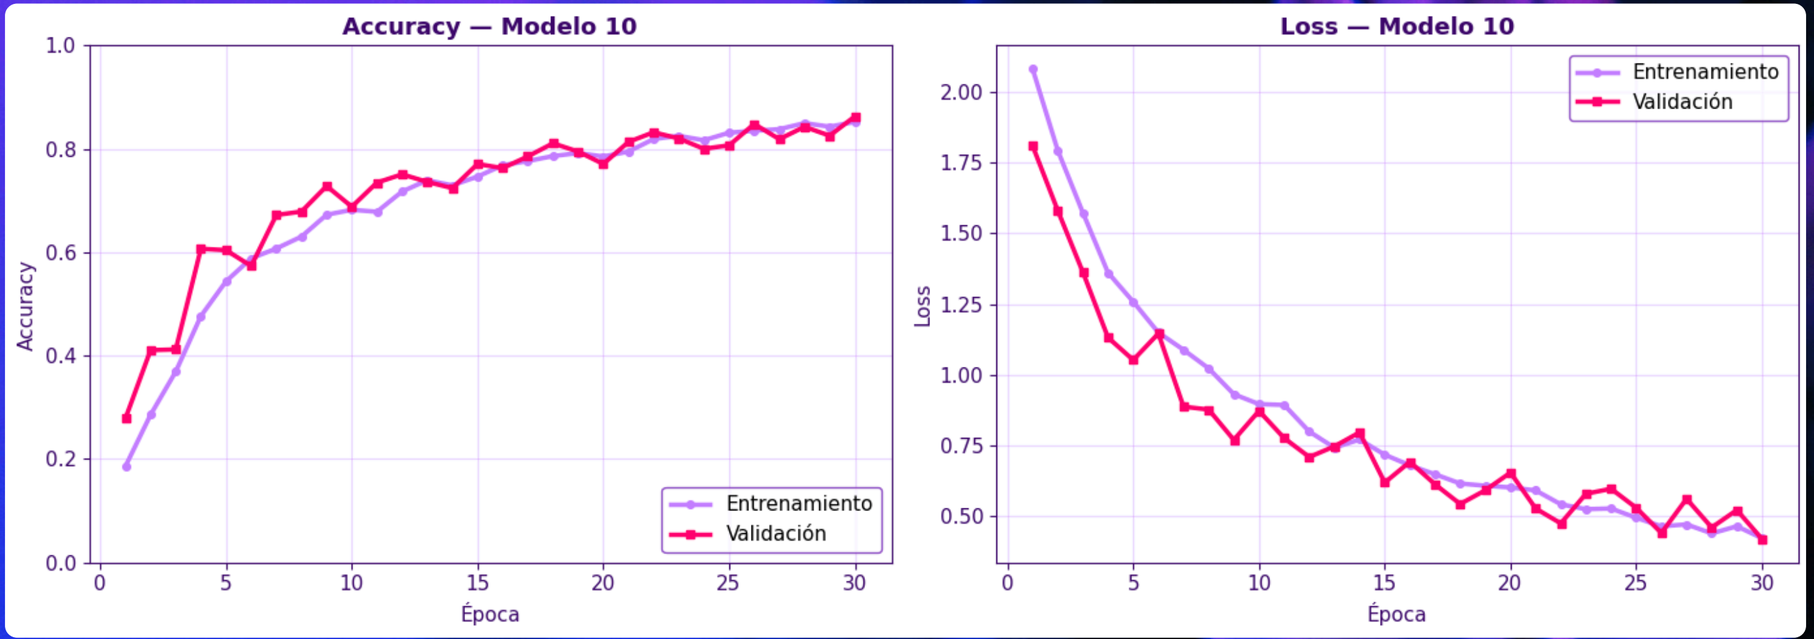
Los 4 bloques experimentales

Bloque	Hipótesis principal	Mejor modelo	Test acc
1 — 300 img/clase	Establecer línea base	Modelo 1 (CNN simple)	0.7067
2 — 500 img/clase	Más datos + profundidad moder	Modelo 6	0.7520
3 — + augmentation	Reducir sobreajuste con augmer	Modelo 8	0.8187
4 — augmentation refinado	Rotaciones 90° sin bordes artifi	Modelo 10	0.8440

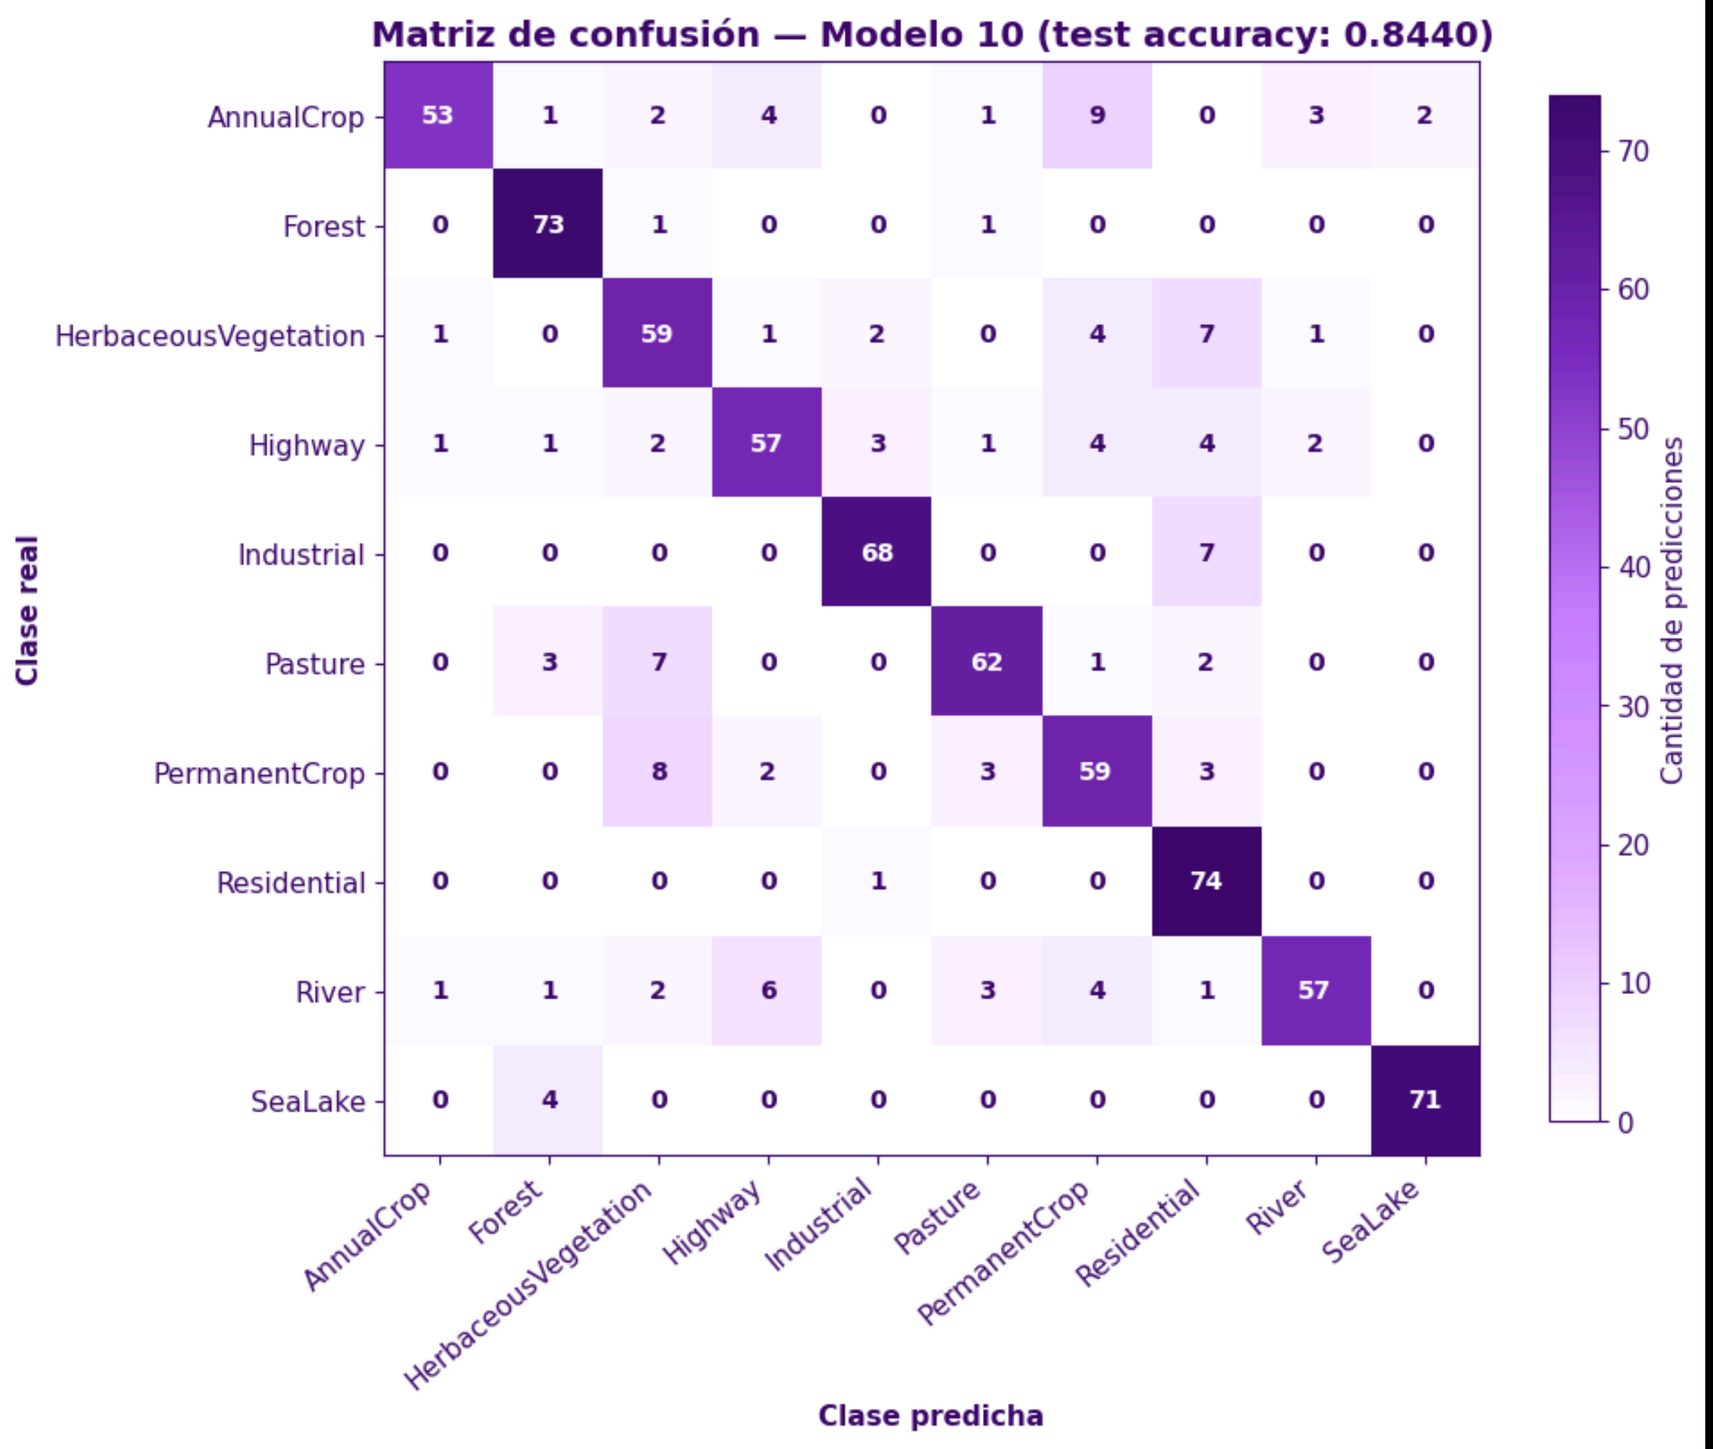
Resultados del Modelo Experimental

"MODELO 10 — TEST ACCURACY: 0.8440"

El Modelo 10 alcanzó una accuracy de prueba de 0.8440, el mejor resultado de la fase experimental. Las curvas de entrenamiento y validación avanzaron prácticamente pegadas durante las 30 épocas, sin signos de sobreajuste: la validación incluso quedó por encima del entrenamiento durante varios tramos, lo cual es esperable cuando el augmentation se aplica solo al conjunto de entrenamiento.
Lo más relevante es que las curvas no convergieron al cortarse: la mejor accuracy de validación (0.8627) y la menor loss de validación (0.4204) se registraron en la última época, lo que sugiere que el modelo todavía tenía margen de mejora con más épocas o más datos.



- Test accuracy: 0.8440
- Test loss: 0.4584
- Mejor val accuracy: 0.8627
- Épocas entrenadas: 30 (techo, no convergencia)
- Sin signos de sobreajuste



Matriz de confusión del modelo final

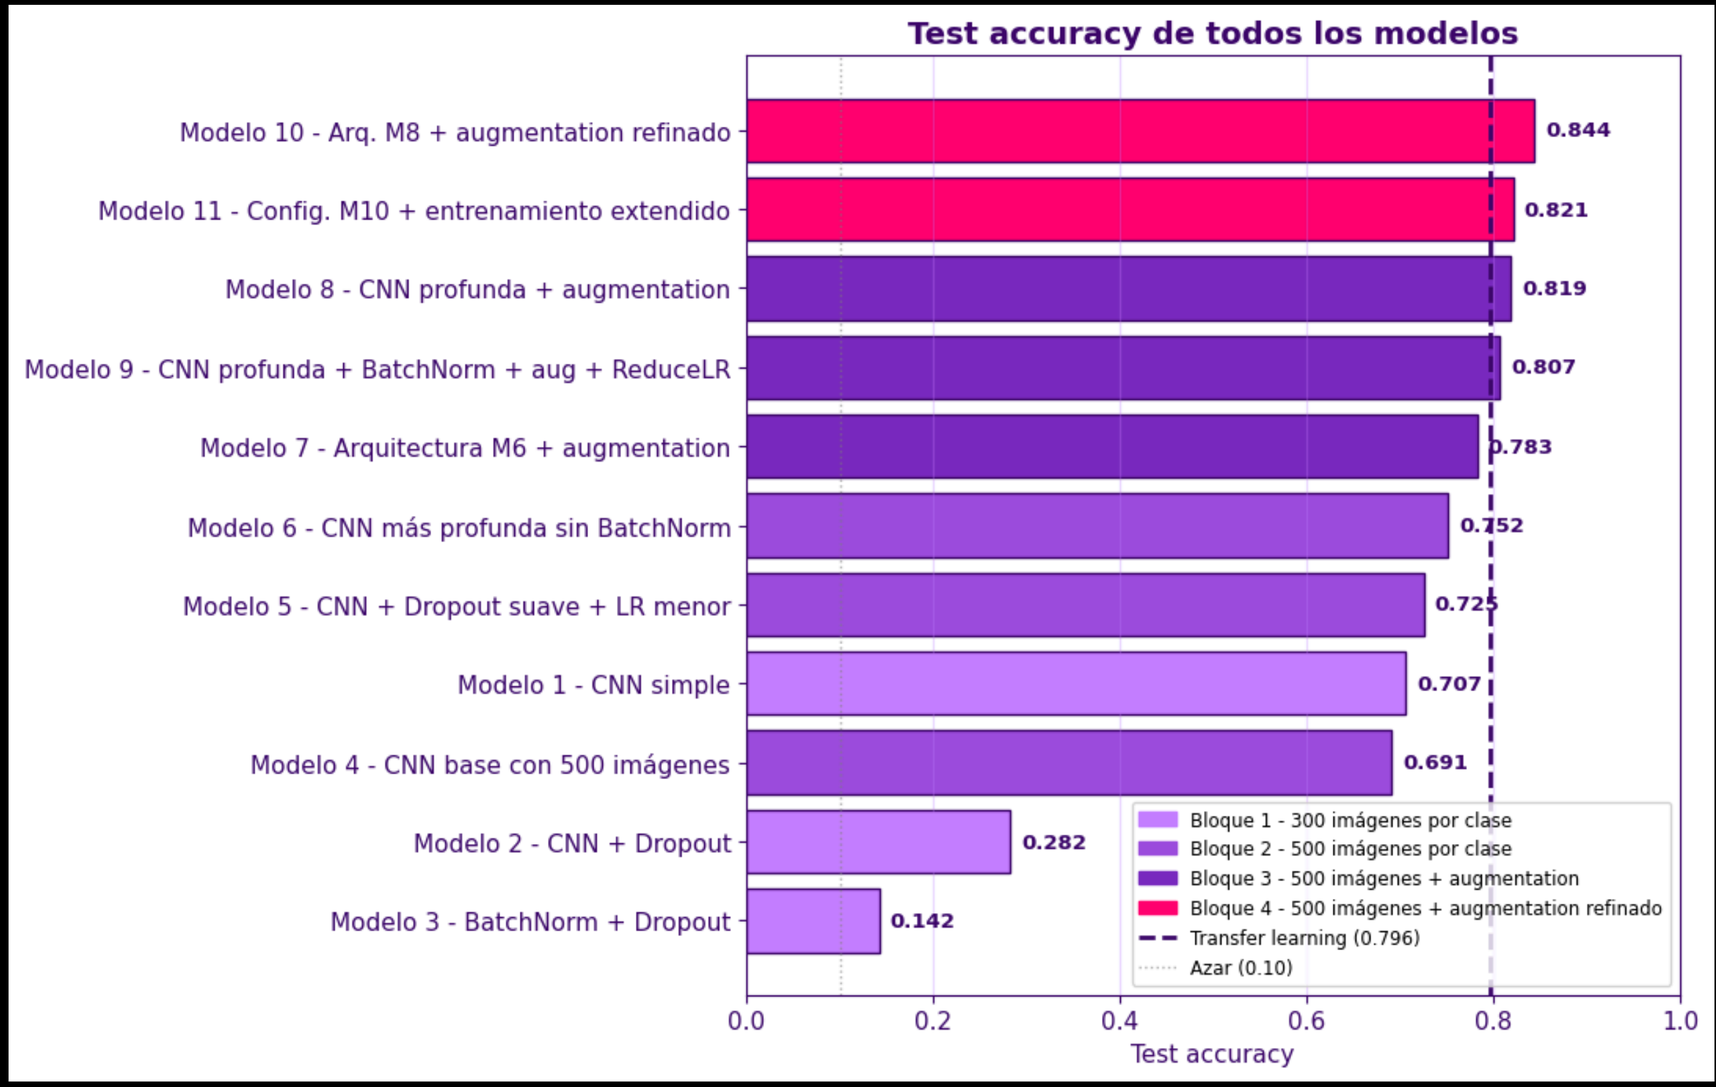
La matriz muestra una diagonal claramente dominante: el modelo acierta la mayoría de las predicciones en todas las clases. Las clases con identidad visual más fuerte (SeaLake, Forest, Industrial, Residential) alcanzan más de 65 aciertos sobre 75 imágenes de prueba.

Las confusiones más frecuentes se concentran en patrones visuales similares:

- River → Highway (13 casos): cursos de agua estrechos y sinuosos comparten la forma alargada con las autopistas.
- Highway → Industrial (7 casos): superficies grises continuas, difíciles de distinguir a 64×64 píxeles.
- AnnualCrop → PermanentCrop (9 casos): tipos de cultivo con tonos de vegetación muy parecidos.

Comparación entre todos los modelos

Los 11 modelos entrenados se ordenan por test accuracy. El gráfico muestra dos cosas a la vez: el rendimiento de cada modelo y a qué bloque experimental pertenece (cada bloque tiene un color distinto en la paleta violeta-magenta).
La progresión visual es clara: los modelos del Bloque 4 (magenta) ocupan los puestos más altos, seguidos por los del Bloque 3 (violeta), Bloque 2 (violeta medio) y Bloque 1 (lavanda). Los dos peores resultados (Modelos 2 y 3) son experimentos fallidos del Bloque 1, donde la regularización agresiva sin datos suficientes destruyó el aprendizaje.
La línea punteada marca el rendimiento de la referencia preentrenada (MobileNetV2 congelada). Todos los modelos del Bloque 4 y la mayoría del Bloque 3 la superan, lo que se discute en detalle en un slide posterior.

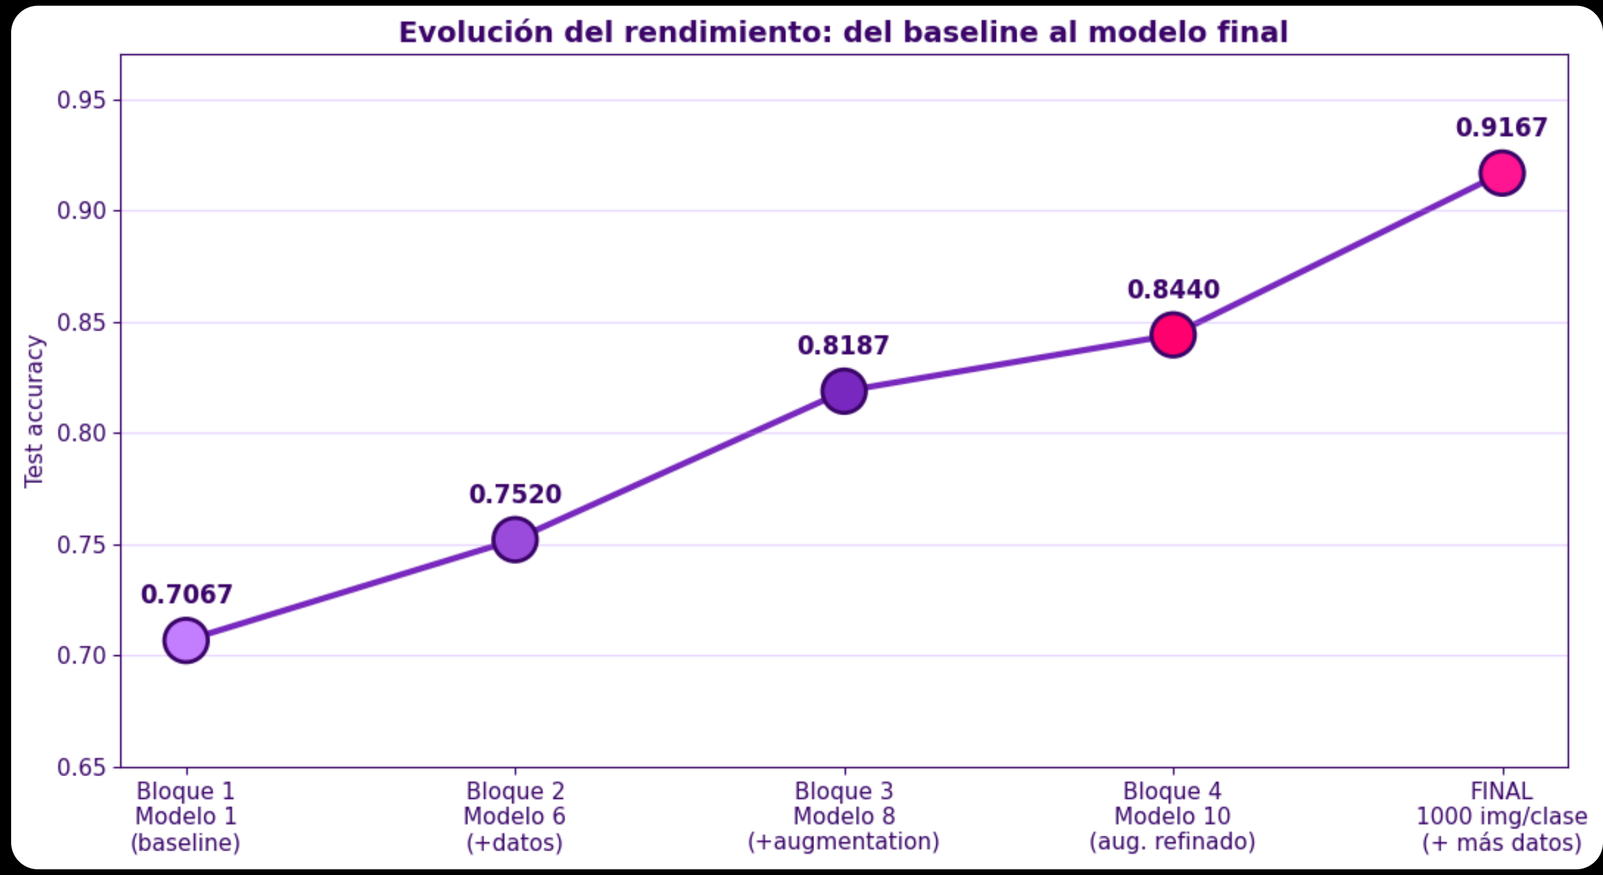


Evolución del Proceso Experimental

Este gráfico es la historia condensada del trabajo: cada punto representa el mejor modelo de su bloque, y la línea muestra cómo cada cambio metodológico produjo una mejora cuantificable.

Transiciones

- Bloque 1 → 2 (+4.5 pts): aumentar la muestra de 300 a 500 imágenes por clase.
- Bloque 2 → 3 (+6.7 pts): introducción del data augmentation, el salto más grande del trabajo.
- Bloque 3 → 4 (+2.5 pts): refinamiento del augmentation con rotaciones de 90° exactos.
- Bloque 4 → Final (+7.3 pts): escalado del modelo ganador a 1.000 imágenes por clase.
- **Del baseline al modelo final: 0.7067 → 0.9167 (+24 puntos).**



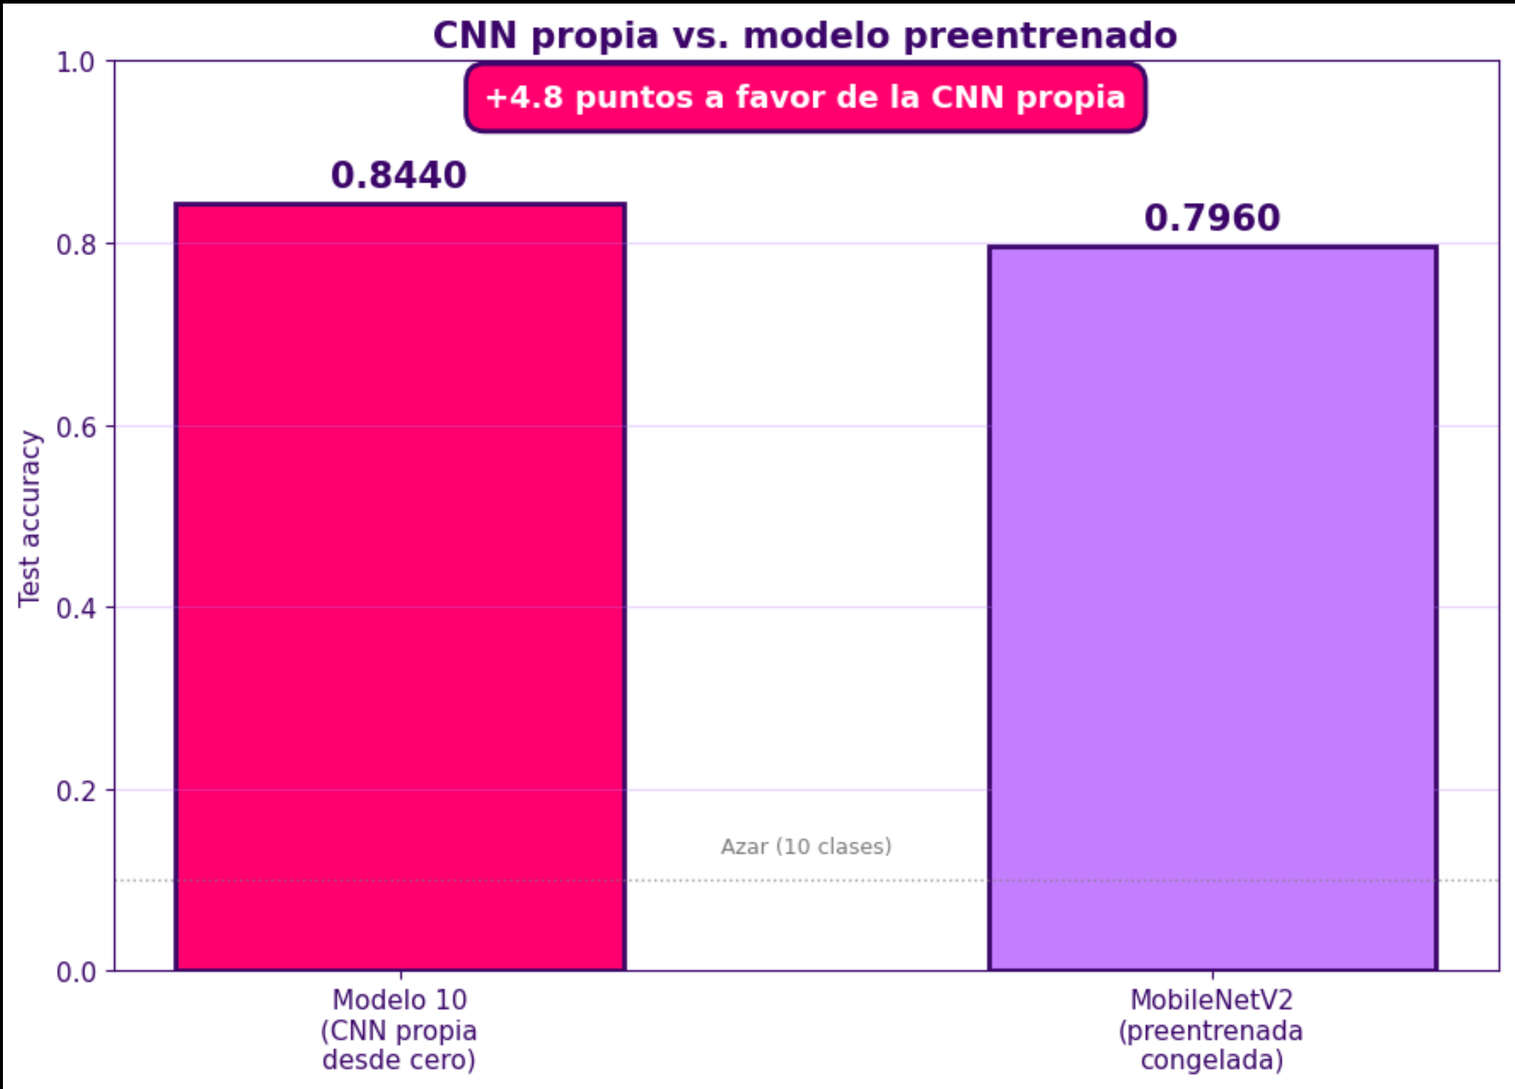
CNN propia vs. modelo preentrenado

"MODELO 10 — TEST ACCURACY: 0.8440"

Como experimento complementario permitido por la consigna, se comparó el modelo propio (entrenado desde cero) con MobileNetV2 preentrenada en ImageNet y con la base congelada. La cabeza de clasificación se entrenó por 12 épocas sobre los mismos datos.

Lo que reveló la comparación:

- La CNN propia superó al modelo preentrenado en +4.8 puntos (0.8440 vs. 0.7960).
- El preentrenado convergió mucho más rápido (alcanzó 0.69 en la primera época), pero se estancó alrededor de 0.80 sin lograr mejorar más.
- Las características de ImageNet (fotografías convencionales de objetos) no están especializadas en imágenes satelitales cenitales, y los pesos están optimizados para entradas de 224×224 píxeles, no 64×64.



Análisis de Errores

¿Dónde y cómo se equivoca?

La inspección visual de los errores confirma que los fallos del modelo se concentran en confusiones objetivamente difíciles a 64×64 píxeles, no en errores aleatorios.

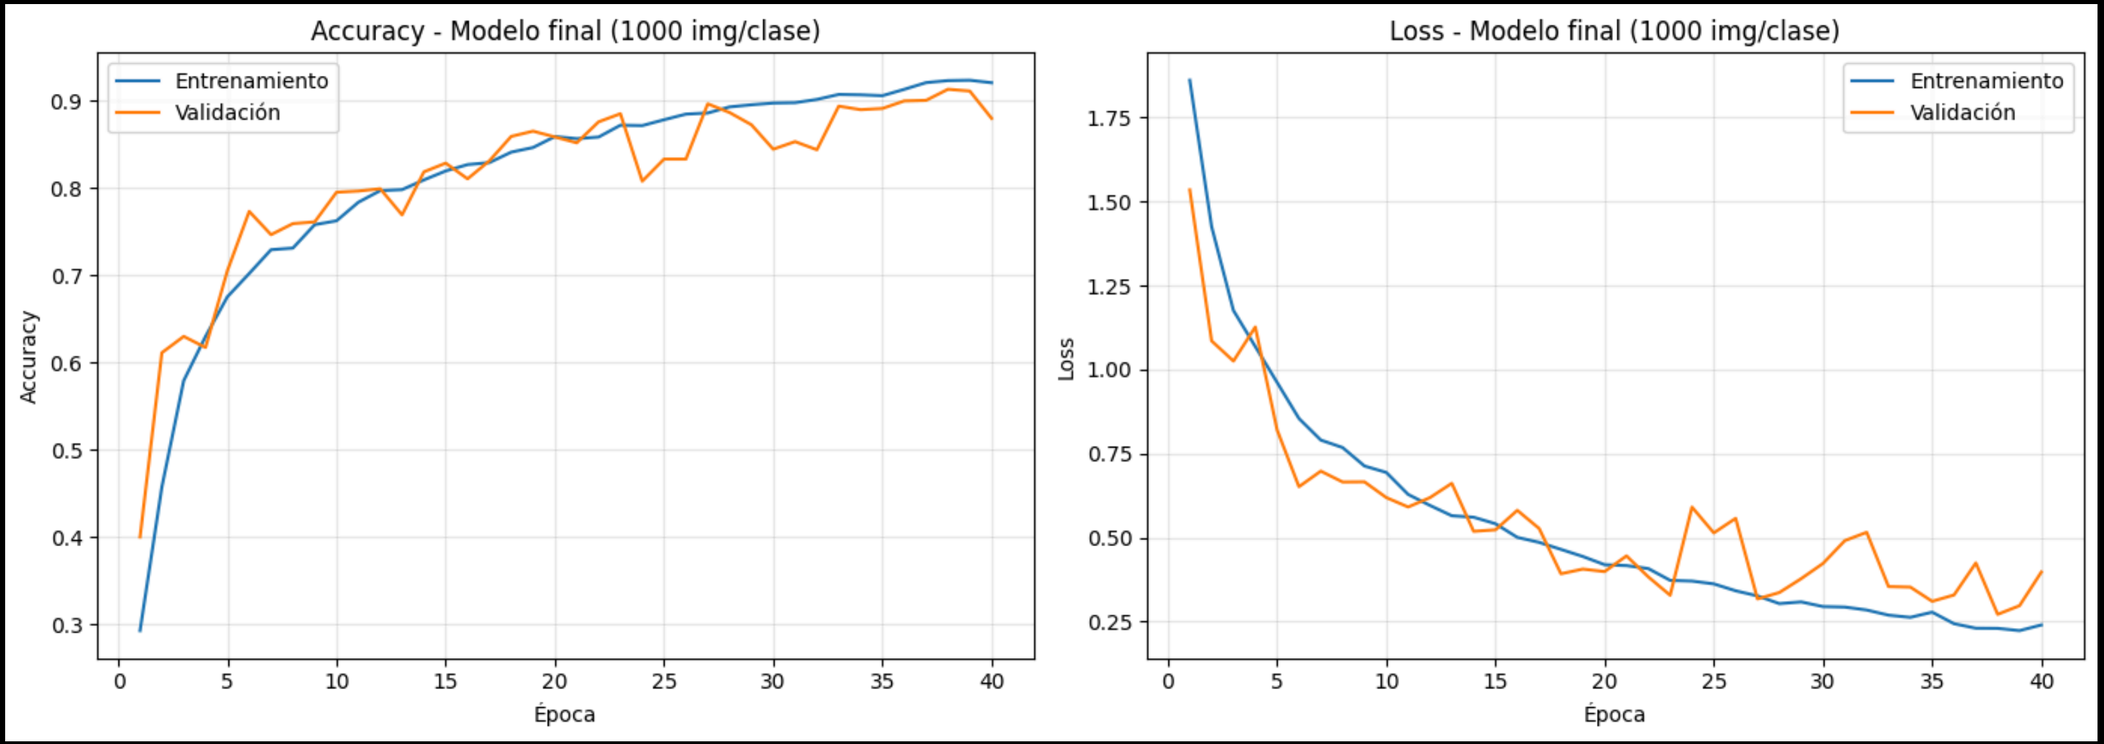
Patrones de error detectados:

- River → Highway: cursos de agua estrechos, sinuosos o cubiertos de vegetación comparten la forma alargada y uniforme con las autopistas.
- Cultivos y vegetación entre sí: parcelas con tonos verdes y marrones muy similares (AnnualCrop, PermanentCrop, HerbaceousVegetation).
- Residential ↔ Industrial: zonas urbanas densas confundidas entre sí cuando los edificios no muestran patrones geométricos claros.



Modelo Final: Escalado a 1.000 imágenes por clase

El Modelo 10 se reentrenó con 1.000 imágenes por clase (el doble) durante 40 épocas, sin cambiar la arquitectura ni el augmentation. El resultado rompió el aparente techo del 84% y alcanzó 91.67% de accuracy, confirmando que el factor decisivo fue siempre la cantidad de datos.



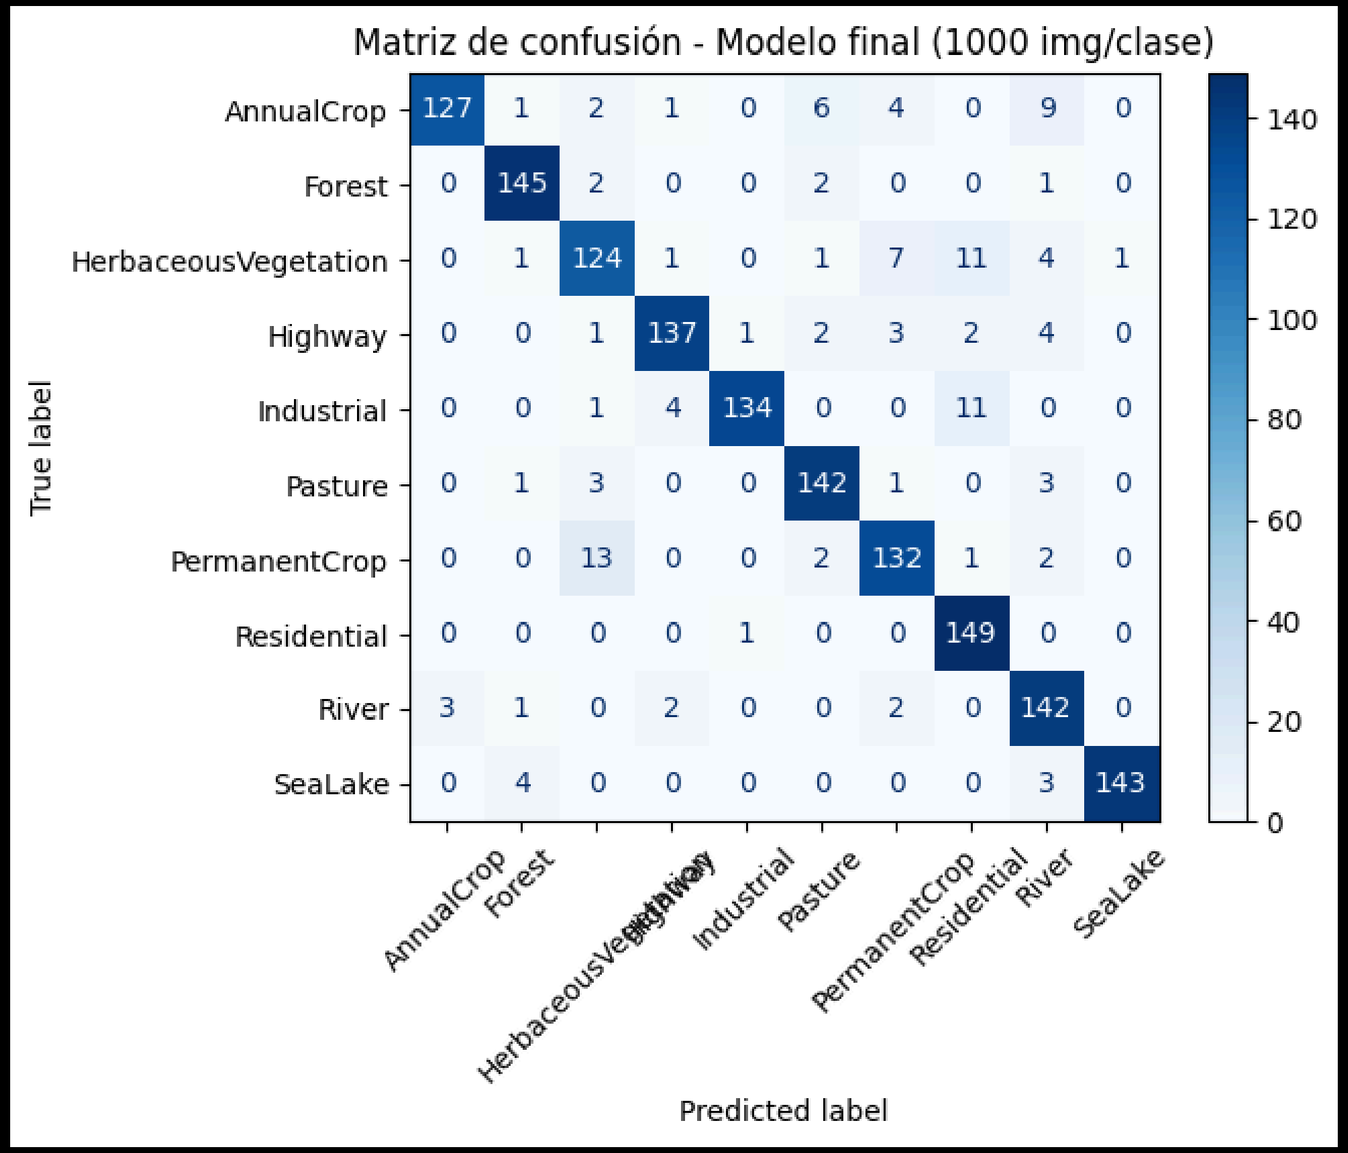
Las curvas de entrenamiento y validación avanzan juntas las 40 épocas: el modelo generaliza mientras aprende.

Evaluación del Modelo Final por Clase

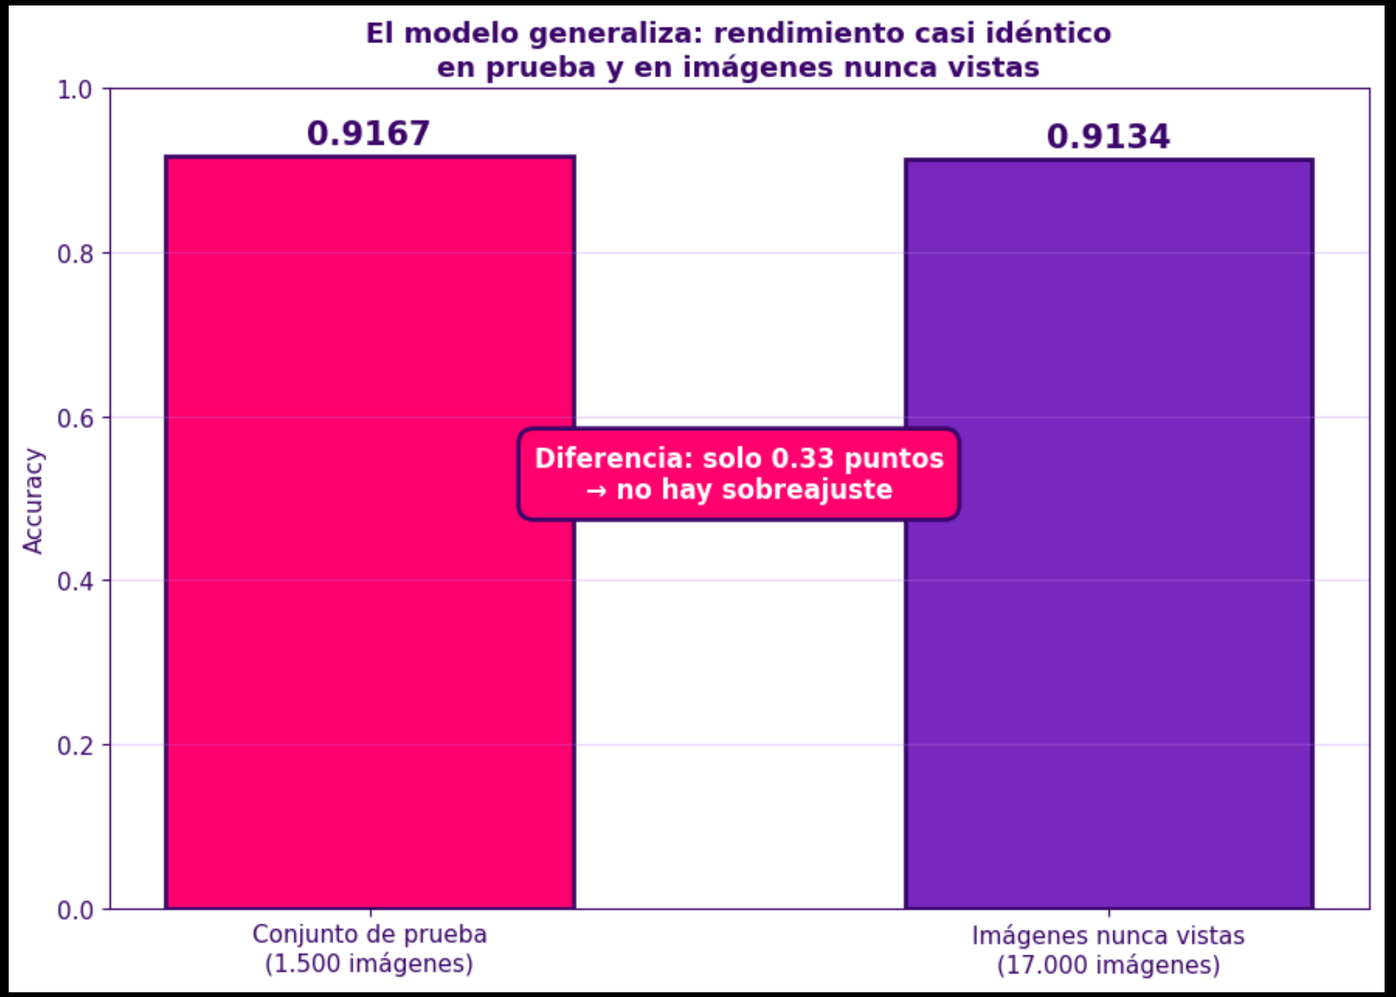
La matriz muestra una diagonal claramente dominante: el modelo acierta la gran mayoría en todas las clases. Las mejores son SeaLake, Forest e Industrial. Las más difíciles siguen siendo los tipos de vegetación y cultivo (HerbaceousVegetation, PermanentCrop), consistente con toda la fase experimental.

Todas las clases con F1 > 0.84
Mejores: SeaLake (0.97), Forest (0.96), Industrial (0.94)
Más difíciles: HerbaceousVegetation (0.84), PermanentCrop (0.88)

Los errores se concentran en clases visualmente similares, no son aleatorios: el modelo aprendió los rasgos discriminativos disponibles a 64×64 píxeles.



Validación sobre 17.000 imágenes nunca vistas

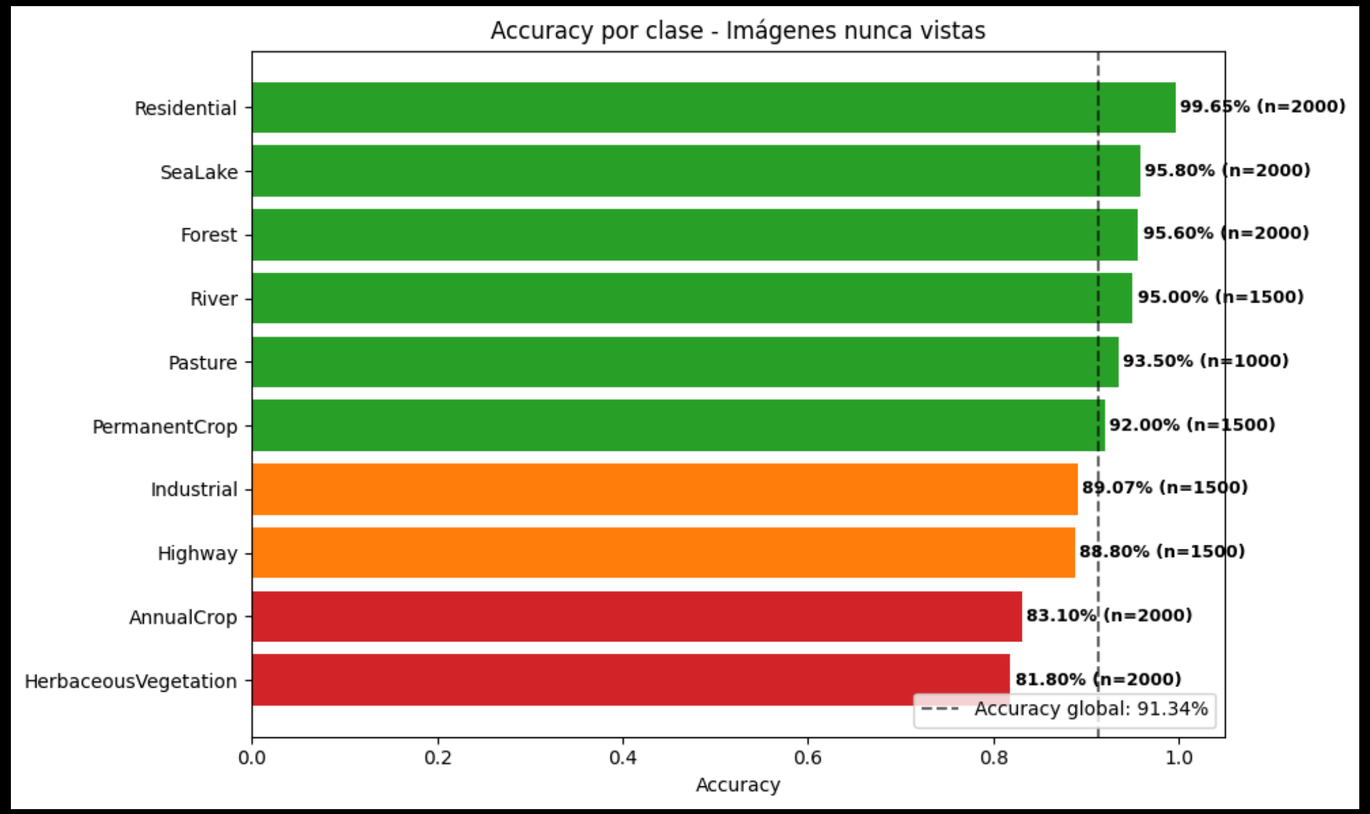


Se evaluó el modelo final sobre las 17.000 imágenes del dataset que no participaron en ningún entrenamiento, validación ni prueba. El resultado —91.34% de accuracy— es casi idéntico al del conjunto de prueba (91.67%). Esta coincidencia demuestra que el modelo generaliza correctamente: aprendió patrones reales en lugar de memorizar sus datos.

17.000 imágenes evaluadas
Accuracy: 0.9134
Confianza promedio: 0.9324
Diferencia con test: solo 0.33 puntos

Rendimiento por clase sobre 17.000 imágenes

Sobre las 17.000 imágenes nunca vistas, las clases con identidad visual fuerte lideran: Residential (99.6%), SeaLake (95.8%) y Forest (95.6%). Las más difíciles siguen siendo HerbaceousVegetation (81.8%) y AnnualCrop (83.1%), por su similitud visual con otros tipos de vegetación a 64×64 píxeles.



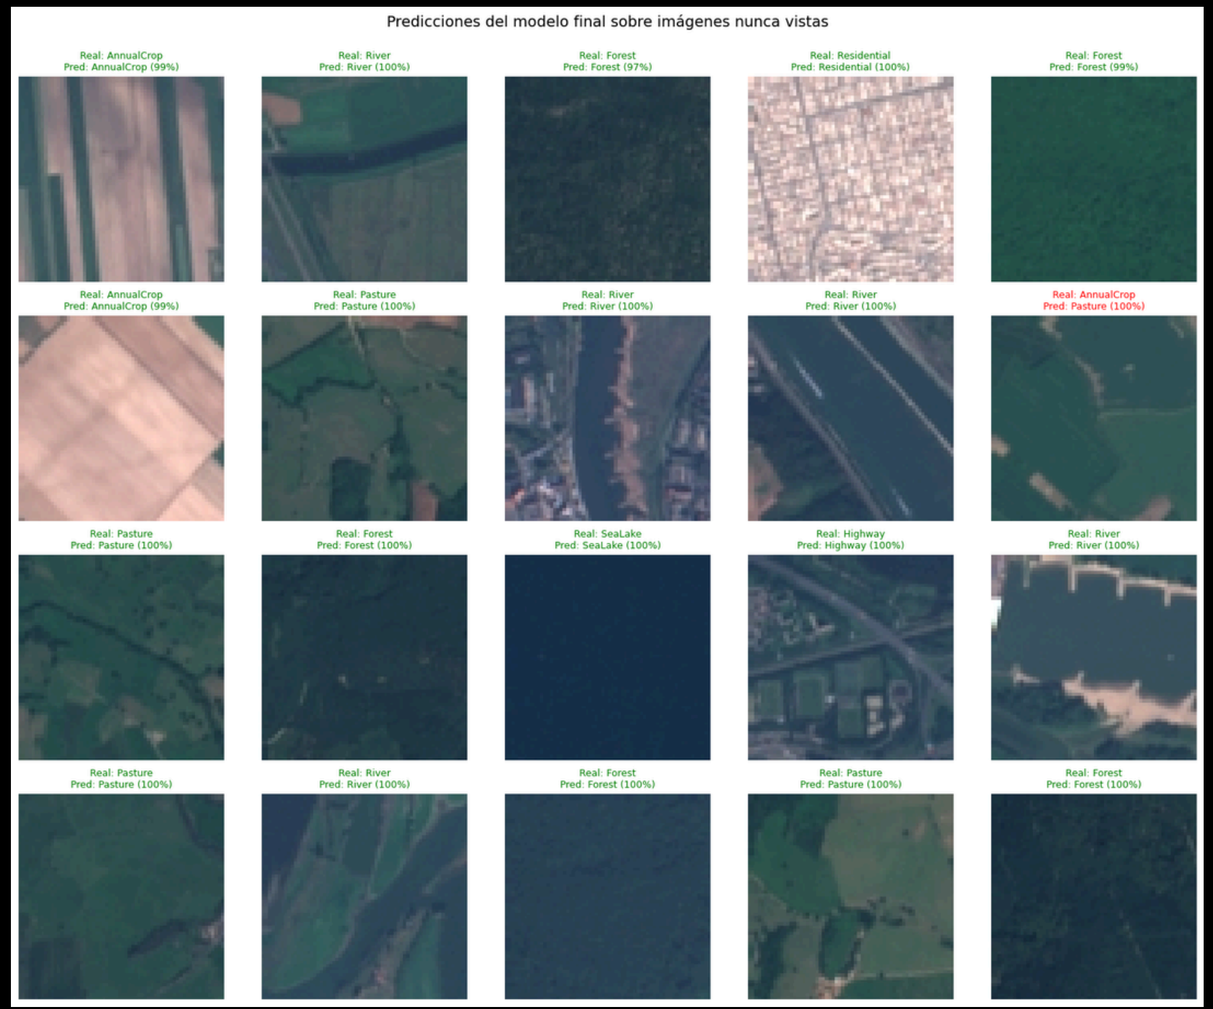
Mejores: Residential, SeaLake, Forest, River (95%+)

Más difíciles: HerbaceousVegetation, AnnualCrop (~82%)

Promedio global: 91.34%

El modelo en Funcionamiento

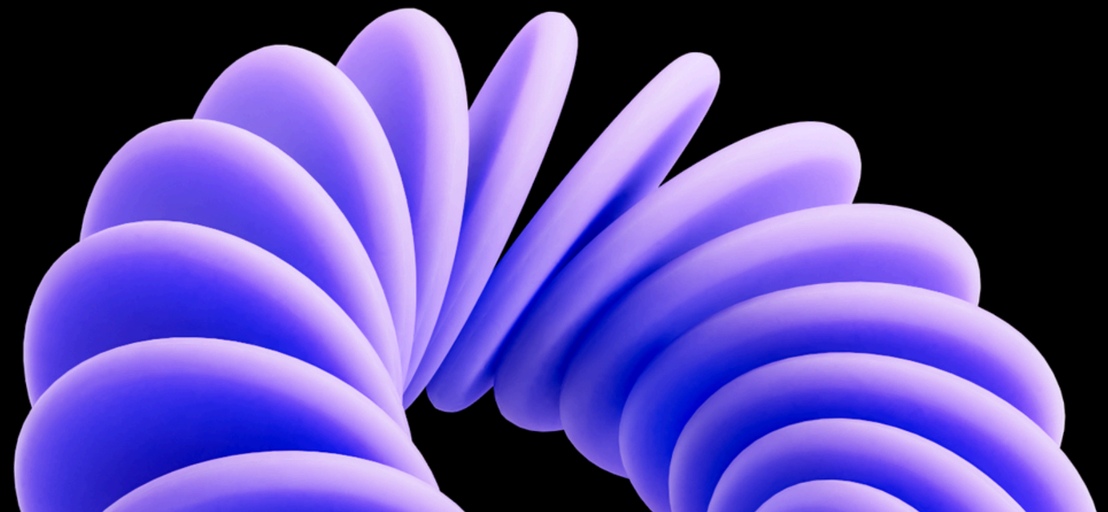
Ejemplos de clasificación sobre imágenes nunca vistas. El modelo predice con alta confianza (mayormente superior al 95%), acertando incluso en clases visualmente difíciles. En verde los aciertos, en rojo los errores.



Conclusiones

Síntesis del trabajo completo: 11 modelos, un proceso experimental controlado y un modelo final validado a gran escala.

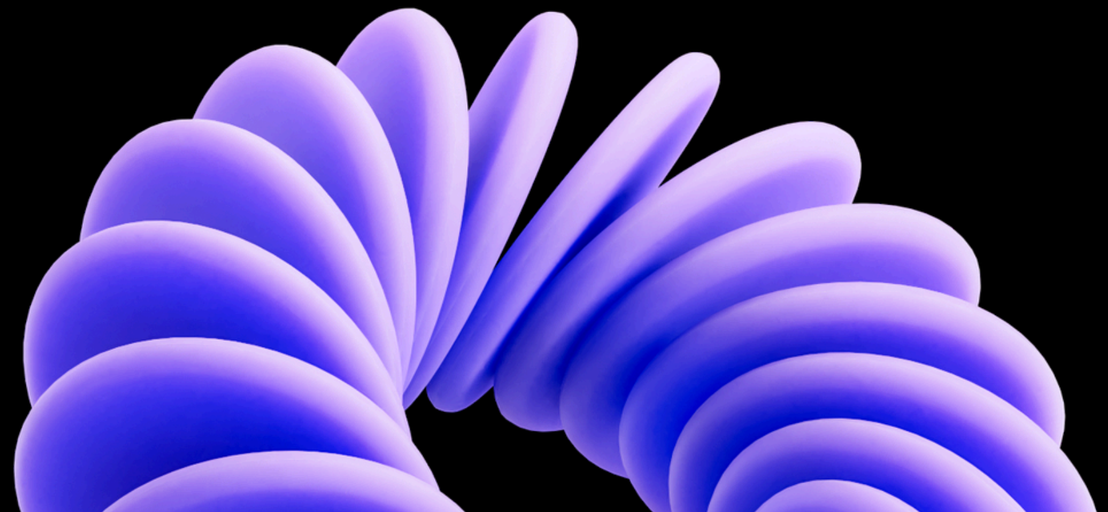
- El modelo final alcanzó 91.67%, escalando la configuración ganadora a 1.000 imágenes por clase.
- El data augmentation fue el factor de mejora más importante de la fase experimental (+6.7 pts).
- El escalado de datos rompió el techo del 84%: el factor decisivo fue siempre la cantidad de datos, no la arquitectura.
- La regularización fuerte sin datos suficientes destruye el modelo (Modelos 2 y 3).
- La CNN propia superó al modelo preentrenado (+4.8 pts), demostrando el valor de un diseño ajustado al problema.
- El modelo generaliza: 91.34% sobre 17.000 imágenes nunca vistas, casi idéntico al test.
-



Mejoras Futuras

Líneas que exceden el alcance de este trabajo y permitirían seguir mejorando el modelo.

- Entrenar con el dataset completo (27.000 imágenes) en un entorno con más recursos de cómputo.
- Incorporar las bandas multiespectrales de EuroSAT (información infrarroja, útil para distinguir tipos de vegetación más allá del RGB).
- Probar fine-tuning de un modelo preentrenado, descongelando parte de la base, como comparación más ambiciosa.
- Promediar varias corridas del modelo final para cuantificar y reducir la variabilidad entre entrenamientos.



¡Gracias por la atención!

Colab Final